HUTECH
Đại học Công nghệ Tp.HCM

Xây dựng ứng dụng phân loại độ chín của Xoài trên điện thoại



SVTH: Nguyễn Hoài Nam
Lê Đoàn Văn Tú
Trần Duy Tân
Nguyễn Hoàng Vũ

GVDH: ThS. Nguyễn Mạnh Hùng

Năm nhóm công nghệ của ứng dụng

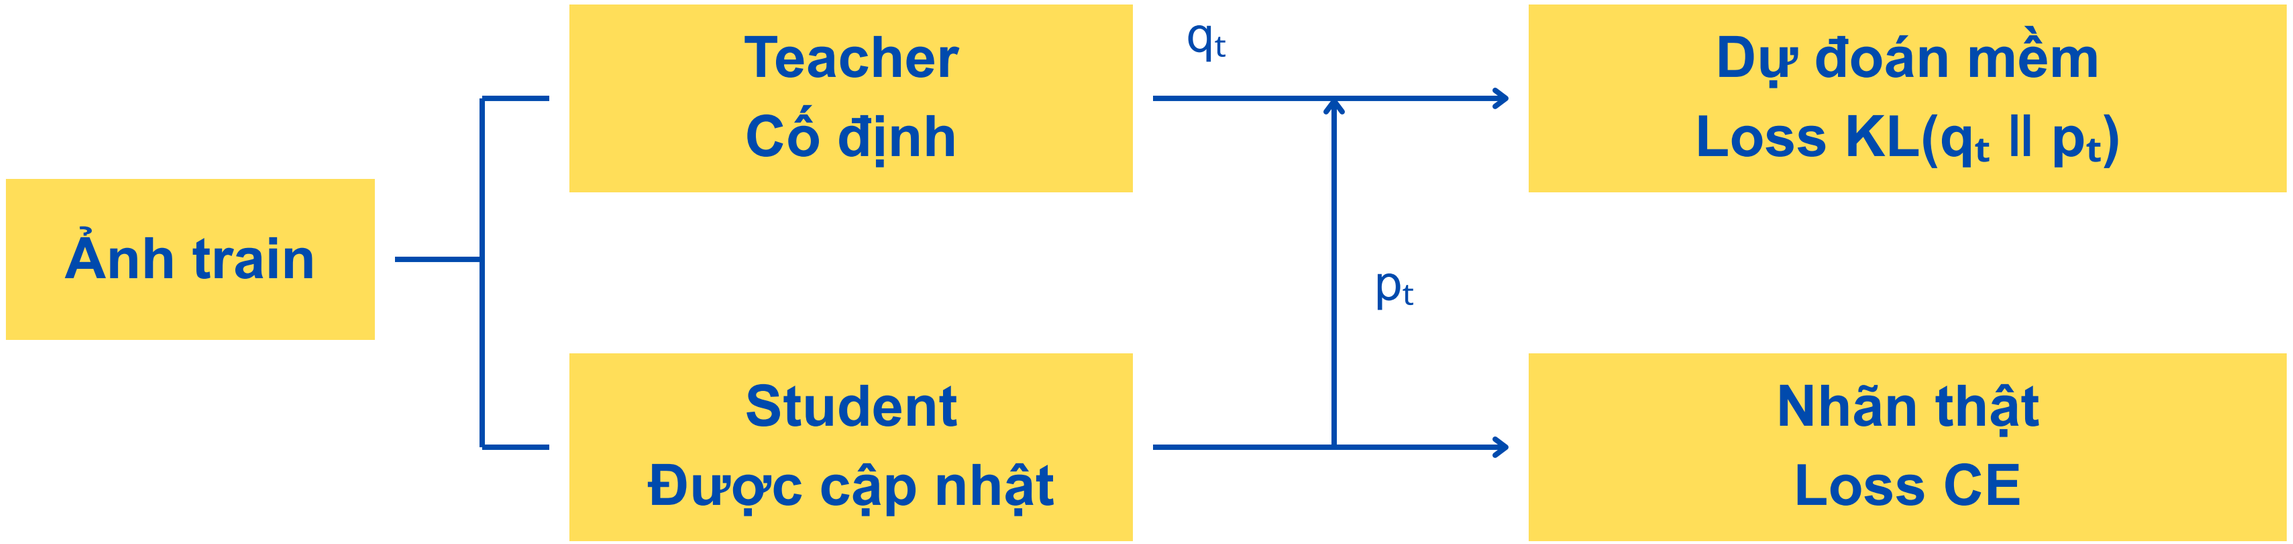
Ứng dụng AI trên điện thoại

- **A Cốt lõi AI**
  ViT, CORAL, chắt lọc kiến thức
- **B Tối ưu AI trên điện thoại**
  Graph, runtime, lượng tử hóa
- **C Giao diện Flutter**
  Widget, trạng thái, kết quả
- **D Đa nền tảng và IoT**
  Android/iOS, BLE, MQTT
- **E Vận hành và phát hành**
  Offline, cập nhật, kiểm thử

A.5 Chắt lọc kiến thức: teacher và student

Teacher cố định, student được cập nhật

Hướng đề xuất: student cần được kiểm chứng



A.6 Loss chắt lọc dự đoán

Cross-entropy và Kullback–Leibler

$$L = \alpha \cdot CE + (1-\alpha) \cdot T^2 \cdot KL(q_t \,\|\, p_t)$$

- CE: học nhãn thật
- KL: học phân bố teacher
- T > 0: độ mềm phân bố
- $0 \le \alpha \le 1$: tỷ trọng hai mục tiêu

Phân bố dùng trong KL

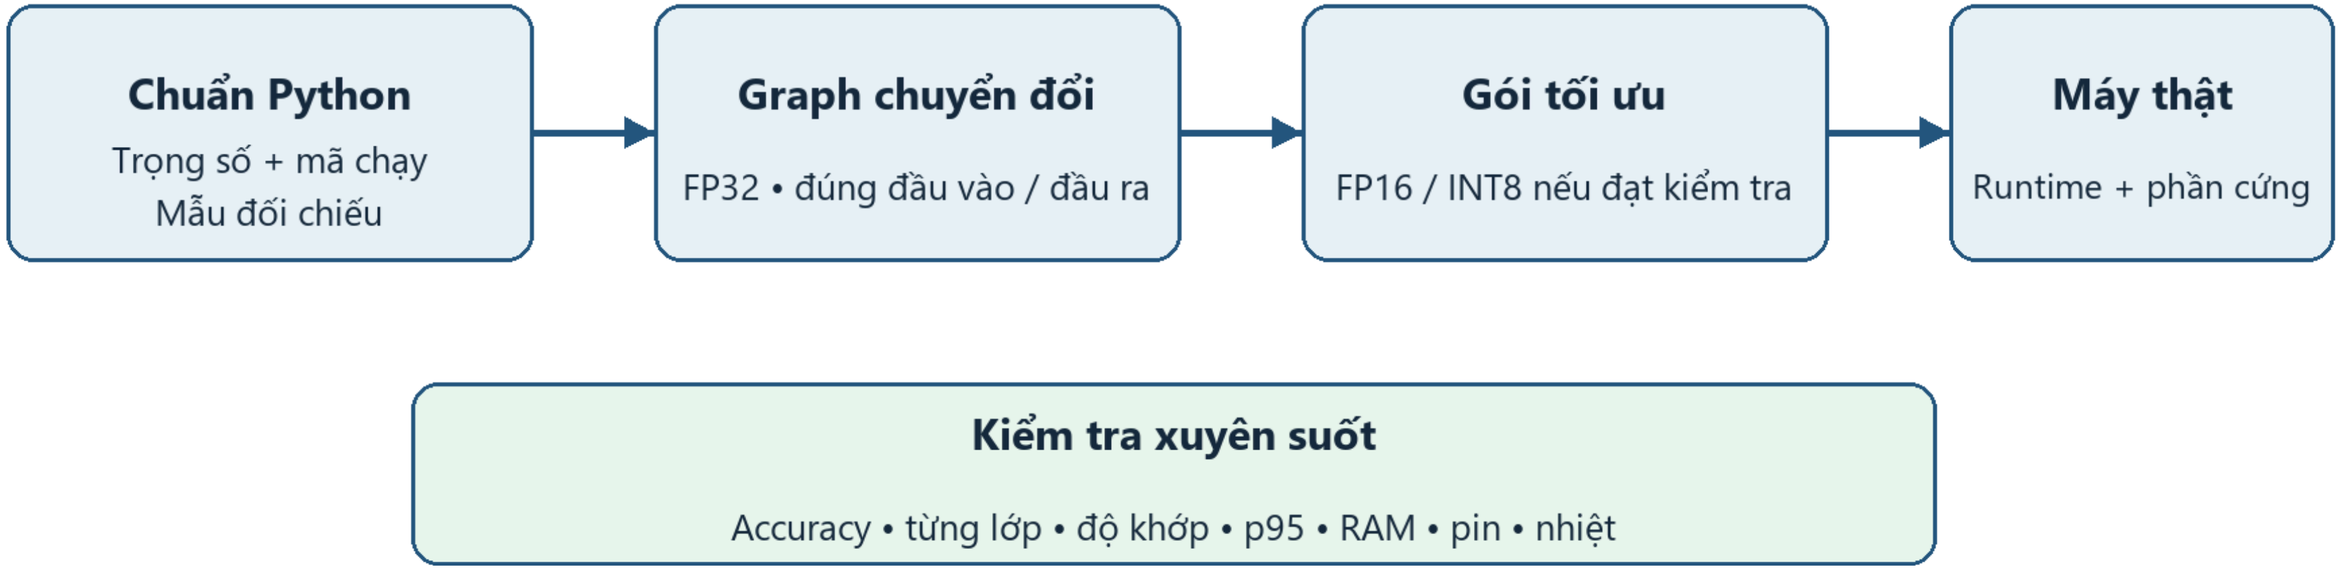
- **q_t = softmax(z_teacher / T)**
- **p_t = softmax(z_student / T)**

T^2 điều chỉnh thang gradient. Nguyên lý chắt lọc, chưa phải cấu hình đã kiểm chứng.

B.1 Graph và runtime trên điện thoại

Graph: đồ thị tính toán. Runtime: thực thi mô hình.

Runtime cần đánh giá: ONNX Runtime, LiteRT, Core ML, ExecuTorch



B.2 FP16, INT8 và lượng tử hóa

PTQ: lượng tử hóa sau huấn luyện
QAT: mô phỏng lượng tử hóa khi huấn luyện

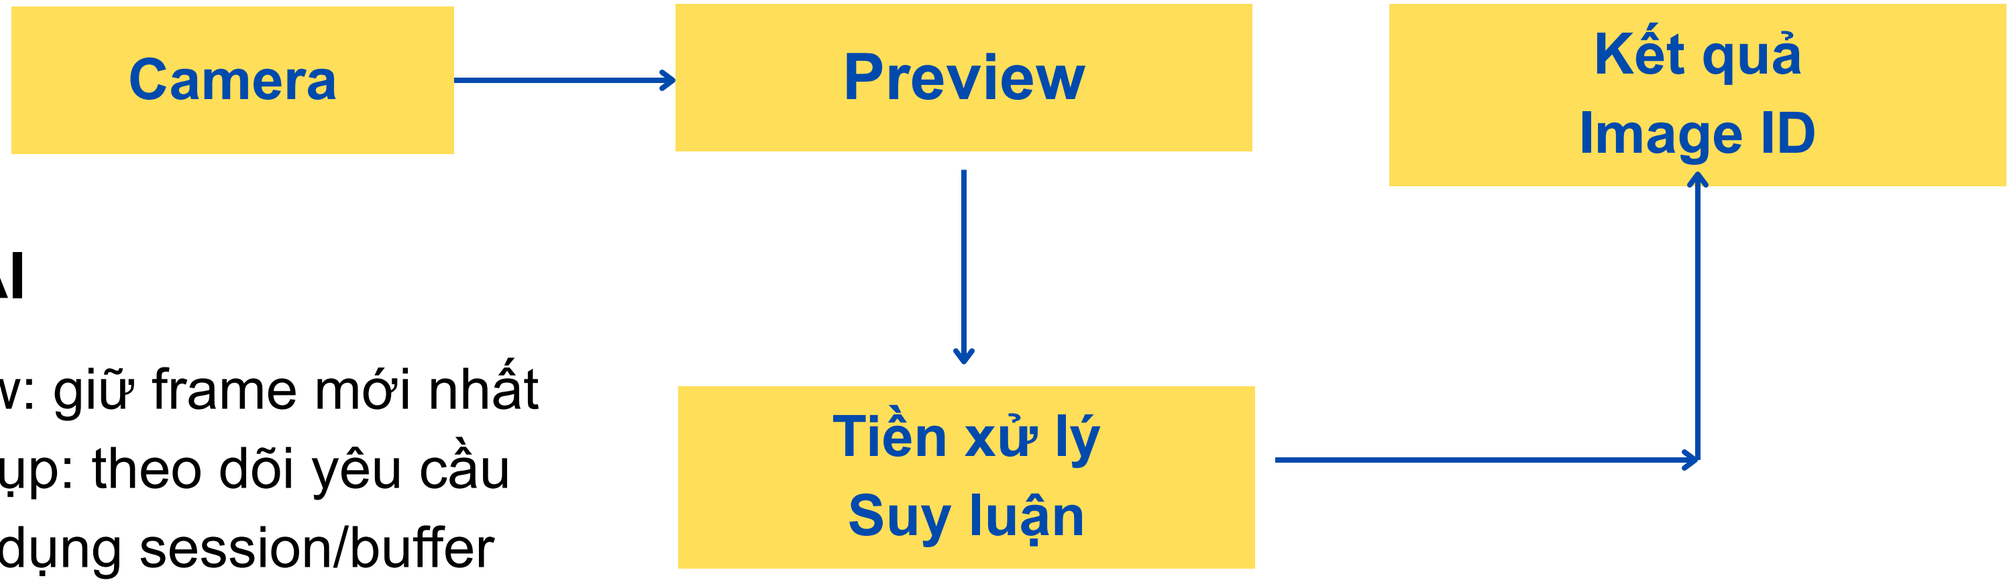
Định dạng	Số bit	Biểu diễn	Vai trò
FP32	32	Số thực	Chuẩn đối chiếu
FP16	16	Số thực	Giảm byte lưu
INT8	8	Scale + zero point	Lượng tử hóa
Mixed	Kết hợp	Ví dụ FP16/FP32	Giữ phần cần FP32

B.3 CPU, GPU và NPU

Thành phần	Vai trò	Điều kiện	Lưu ý
CPU	Tính toán đa dụng	Kernel runtime	Chuẩn đối chiếu
GPU	Tính toán song song	Toán tử + dtype	Chuyển dữ liệu
NPU	Xử lý mạng nơ-ron	Backend theo máy	Graph có thể bị chia
Fallback	Phần thiếu về CPU	Kernel + cấu hình	Chưa chắc nhanh

B.4 Camera và điều phối suy luận

Thiết kế đề xuất: UI hiển thị preview và nhận thao tác



Worker AI

- Preview: giữ frame mới nhất
- Ảnh chụp: theo dõi yêu cầu
- Tái sử dụng session/buffer theo API và vòng đời

D.1 Flutter và tích hợp native

Tích hợp đề xuất: Flutter/Dart dùng chung giao diện và logic

Platform Channel: yêu cầu/kết quả

Pigeon: sinh mã giao tiếp có kiểu

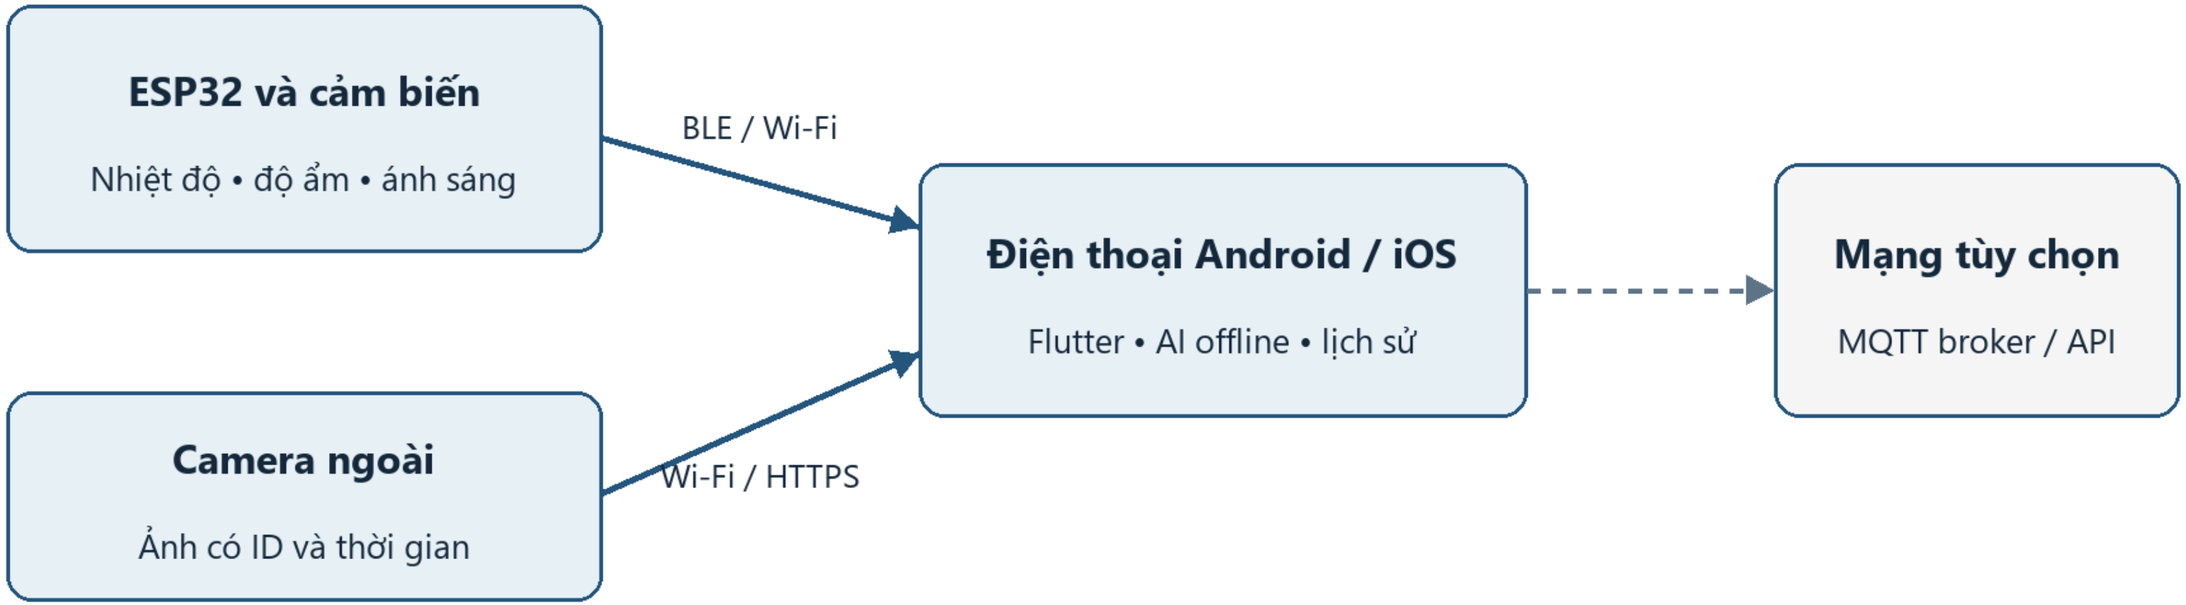
Android
Kotlin + runtime

iOS
Swift + runtime

D.2 ESP32 và kết nối IoT đề xuất

ESP32 · ESP-IDF / FreeRTOS

BLE: cảm biến gần · Wi-Fi/HTTPS: ảnh và dữ liệu lớn



D.3 MQTT: gửi và nhận theo topic

Topic: định tuyến bản tin theo chủ đề



- QoS 0: tối đa một lần
- QoS 1: ít nhất một lần, có thể lặp
- QoS 2: đúng một lần ở cơ chế giao tin MQTT
- Event ID + xử lý idempotent cho nghiệp vụ

Trân trọng cảm ơn!